Analisis Sentimen Publik terhadap Kinerja Pemerintahan Indonesia di Media Sosial Menggunakan Ensemble Model Transformer dan Koreksi Berbasis Aturan

Penulis: Sandy Wiraabdy · Oktober 2026

Abstrak

Penelitian ini menganalisis sentimen publik terhadap kinerja pemerintahan Indonesia berdasarkan data media sosial (Facebook, Instagram, dan Twitter/X) yang dikumpulkan melalui layanan scraping Apify. Klasifikasi sentimen (positif, netral, negatif) dilakukan dengan ensemble dua model transformer, yaitu IndoRoBERTa dan XLM-RoBERTa (Twitter), dengan rata-rata probabilitas kelas. Hasil klasifikasi dikoreksi menggunakan aturan deteksi sarkasme berbasis pola kata, serta dilengkapi penanda kritik, apresiasi, dan konten meme. Dari 167 data asli, diperoleh sentimen positif 15,6% (26 data), netral 47,3% (79 data), dan negatif 37,1% (62 data), dengan Indeks Sentimen Bersih 39,2 pada skala 0–100 yang menunjukkan kecenderungan negatif. Konten meme/sindiran seluruhnya (100%) bersentimen negatif. Sentimen negatif tertinggi tampak pada Instagram (47%) dan Twitter/X (40%), sedangkan Facebook didominasi netral (77%). Temuan ini perlu ditafsirkan hati-hati karena data Facebook berasal dari unggahan akun media berita, bukan opini warga, dan klasifikasi topik berbasis kata kunci masih menimbulkan salah label.

Kata kunci: analisis sentimen, kinerja pemerintahan, media sosial, ensemble learning, RoBERTa, sarkasme, indeks sentimen bersih

Abstract

This study analyses public sentiment toward the performance of the Indonesian government using social media data from Facebook, Instagram and Twitter/X. Sentiment is classified (positive, neutral, negative) by averaging the class probabilities of two transformer models and is then corrected by rule-based sarcasm detection. Of 167 genuine posts, 15.6% were positive, 47.3% neutral and 37.1% negative, giving a Net Sentiment Index of 39.2 (0–100 scale), i.e. a negative tendency. All meme/satire content was negative. Findings are limited by the news-outlet origin of Facebook data and by keyword-based topic tagging.

Keywords: sentiment analysis, government performance, social media, ensemble learning, sarcasm

1. Pendahuluan

Media sosial menjadi ruang utama masyarakat Indonesia untuk menyampaikan keluhan, kritik, maupun apresiasi terhadap program pemerintah seperti bantuan sosial, layanan kesehatan, pendidikan, dan pembangunan infrastruktur. Survei opini konvensional membutuhkan waktu dan biaya besar, sedangkan analisis sentimen otomatis memungkinkan pemantauan opini publik secara cepat dan berkelanjutan.

Tantangan khusus pada bahasa Indonesia di media sosial meliputi bahasa informal dan singkatan, campuran bahasa, serta penggunaan sarkasme dan meme politik yang secara literal tampak positif

(misalnya “terima kasih pak, kami sangat bahagia”) padahal bermakna sindiran. Model sentimen umum sering salah mengklasifikasikan kalimat semacam ini.

Penelitian ini bertujuan: (1) membangun alur pengumpulan dan analisis sentimen multi-platform terhadap isu kinerja pemerintahan; (2) meningkatkan akurasi dengan ensemble model dan koreksi sarkasme; (3) merumuskan indikator ringkas berupa Indeks Sentimen Bersih beserta selang kepercayaannya; dan (4) menguraikan sentimen menurut platform, topik program, serta jenis konten (meme vs non-meme).

2. Metodologi

2.1 Pengumpulan Data

Data dikumpulkan menggunakan Apify Client dengan batas maksimum 100 item per platform (MAX_PER_PLATFORM = 100). Sumber dan aktor yang digunakan adalah sebagai berikut.

Platform	Aktor Apify	Strategi pengambilan
Facebook	apify/facebook-posts-scraper	Halaman detikcom, kompascom, cnnindonesia
Instagram	apify/instagram-hashtag-scraper	Hashtag dari daftar kata kunci
TikTok	clockworks/tiktok-scraper	Pencarian kata kunci
Twitter/X	apidojo/tweet-scraper	Pencarian kata kunci, urutan terbaru

Daftar kata kunci mencakup tiga kelompok: program dan kebijakan (misalnya bansos PKH, BPJS Kesehatan, KIP Kuliah, IKN Nusantara, makan bergizi gratis), kritik dan keluhan rakyat (misalnya harga sembako naik, jalan rusak, PHK buruh), serta meme dan sindiran (misalnya meme politik, janji manis). Apabila data asli suatu platform kurang dari ambang minimum (MIN_ASLI = 5), sistem menambahkan data dummy sebagai cadangan. Kolom sumber menandai data sebagai “asli” atau “dummy”.

2.2 Pembersihan Data

Teks dipangkas spasi, teks kurang dari 15 karakter dibuang, dan duplikat dihapus berdasarkan isi teks. Metadata dirapikan: author kosong menjadi “Anonim”, followers kosong menjadi 0 (bilangan bulat), tanggal dari timestamp Unix diformat ke YYYY-MM-DD HH:MM (nilai lebih dari 10^11 dianggap milidetik dan dibagi 1000), serta nilai kosong pada acc_created dan url diganti “-”.

2.3 Penandaan Topik dan Meme

Setiap teks diberi satu label topik melalui pencocokan kata kunci pada kamus sembilan kategori: Bansos & Perlinsos, Kesehatan (BPJS/KIS), Pendidikan (KIP/Beasiswa), Ekonomi & Harga, Infrastruktur, Korupsi & Hukum, Layanan Publik, Ketenagakerjaan, serta Politik & Janji. Aturannya: teks diubah ke huruf kecil, lalu kategori pertama yang memiliki salah satu kata kuncinya terkandung dalam teks dipilih; jika tidak ada, labelnya “Lainnya”. Konten meme dideteksi dengan ekspresi reguler (misalnya pov, meme, ceritanya, klasik, oke sip, katanya, padahal) dan menghasilkan penanda boolean meme_flag.

2.4 Pra-pemrosesan Teks

Sebelum masuk model, teks dibersihkan: tautan dan sebutan akun (@user) dihapus, tanda pagar diubah menjadi kata biasa, huruf berulang lebih dari tiga kali dipadatkan menjadi dua (“baguuuus” menjadi

“baguus”), dan spasi berlebih dirapikan. Teks hasil pembersihan yang kurang dari 5 karakter dibuang. Panjang token dibatasi 128 (MAX_LEN) dengan batch 32.

2.5 Model Klasifikasi dan Ensemble

Dua model transformer yang telah dilatih untuk sentimen digunakan.

- **w11wo/indonesian-roberta-base-sentiment-classifier**, model RoBERTa berbahasa Indonesia.
- **cardiffnlp/twitter-xlm-roberta-base-sentiment**, model XLM-RoBERTa multibahasa yang dilatih pada data Twitter (label LABEL_0, LABEL_1, LABEL_2 dipetakan ke negatif, netral, positif).

Untuk teks ke-i, setiap model m menghasilkan vektor probabilitas tiga kelas (hasil softmax):

$p_m(i) = [P(\text{negatif}), P(\text{netral}), P(\text{positif})]$, dengan jumlah komponen = 1

Ensemble dilakukan dengan merata-ratakan probabilitas dari M model (di sini M = 2):

$p(i) = (1/M) \times \Sigma_m\ p_m(i)$

Label akhir adalah kelas dengan probabilitas tertinggi, dan skor keyakinan adalah nilai probabilitas tertinggi tersebut:

$label(i) = argmax_k\ p_k(i)$

$skor(i) = max_k\ p_k(i)$

Prediksi dianggap ragu-ragu (low_confidence) bila skor < 0,55. Rata-rata probabilitas bersifat stabil karena kesalahan satu model dapat diimbangi model lain; nilai 0,55 dipilih karena pada tiga kelas, skor di bawah ambang ini menunjukkan keputusan yang tidak tegas.

Contoh ilustrasi (angka hipotetis). Model A memberi [0,10; 0,20; 0,70] dan model B memberi [0,30; 0,30; 0,40] untuk satu teks. Rata-ratanya [0,20; 0,25; 0,55], sehingga label = Positif dengan skor 0,55 (tepat di batas keraguan).

2.6 Koreksi Sarkasme

Model umum membaca makna literal. Karena itu, teks berlabel Positif yang mengandung pola sarkasme politik (misalnya “katanya”, “oh iya”, “klasik”, “oke sip”, “maaf pak”, “padahal”, “janji manis”, “terima kasih pak … (gagal/rusak/mahal)”) diubah menjadi Negatif dan ditandai sarkasme_flag. Secara formal:

jika label(i) = Positif DAN teks(i) cocok dengan pola sarkasme, maka label(i) ← Negatif

Koreksi hanya berlaku satu arah (Positif ke Negatif) sehingga tidak mengubah teks netral.

2.7 Penanda Kritik dan Apresiasi

Dua penanda tambahan berbasis kata kunci dihitung terpisah dari label sentimen: kritik_flag (kata seperti gagal, korupsi, mahal, rusak, mengecewakan, “prioritas apa”, “ke mana”) dan apresiasi_flag (kata seperti sangat membantu, bermanfaat, memudahkan, lanjutkan, responsif). Penanda ini memberi gambaran intensitas isi, bukan pengganti label model.

2.8 Indeks Sentimen Bersih (ISB)

Setiap label dikonversi menjadi skor numerik s: Positif = +1, Netral = 0, Negatif = −1. ISB adalah rata-rata skor yang diskalakan ke rentang 0–100:

$$ISB = \text{rata-rata}(s) \times 50 + 50$$

Karena rata-rata(s) = (n_pos − n_neg) / n, rumusnya setara dengan:

$$ISB = 50 + 50 \times (n_{pos} - n_{neg}) / n$$

Nilai 50 berarti opini seimbang (positif = negatif), di atas 50 cenderung positif, dan di bawah 50 cenderung negatif. Netral tidak mengubah arah indeks, hanya mengecilkan jaraknya dari 50.

2.9 Selang Kepercayaan dengan Bootstrap

Ketidakpastian ISB diperkirakan dengan bootstrap persentil (Efron, 1979). Prosedurnya: (1) ambil sampel acak dengan pengembalian berukuran n dari seluruh data; (2) hitung ISB sampel; (3) ulangi 2.000 kali (seed 42); (4) selang kepercayaan 95% adalah persentil ke-2,5 dan ke-97,5 dari 2.000 nilai tersebut:

$$CI95\% = [P2{,}5 \; ; \; P97{,}5] \text{ dari } \{ISB^*_1, \ldots, ISB^*_{2000}\}$$

2.10 Persentase dan Tabel Silang

Persentase kelas: $\%\ \text{kelas}\ k = (n_k / n) \times 100$. Tabel sentimen per platform, per topik, dan meme vs non-meme dinormalisasi per baris (normalize = “index”), sehingga setiap baris berjumlah 100% dan membandingkan komposisi sentimen antar kelompok, bukan jumlah mutlaknya. Kolom n pada tabel menunjukkan ukuran tiap kelompok.

3. Hasil

3.1 Gambaran Data

Laporan PDF menyebut 177 data dianalisis, sedangkan grafik dihitung dari 167 data. Selisih 10 data terjadi karena Cell 5 hanya memakai baris bersumber “asli” (jumlahnya ≥ 30), sehingga 10 data dummy dikeluarkan dari perhitungan. Seluruh angka hasil di bawah ini mengacu pada 167 data asli, dengan label grafik “data asli”. Konten meme/sindiran yang tercatat pada ringkasan PDF adalah 14 data (dihitung dari 177 data).

3.2 Distribusi Sentimen Keseluruhan

Sentimen	Jumlah	Persentase
Positif	26	15,6%
Netral	79	47,3%
Negatif	62	37,1%
Total	**167**	**100%**

Sentimen netral paling banyak, diikuti negatif; positif adalah yang paling sedikit. Rasio negatif terhadap positif sekitar 2,4 : 1 (62 / 26).

3.3 Indeks Sentimen Bersih

Perhitungan: rata-rata(s) = (26 − 62) / 167 = −0,2156, sehingga

$$ISB = (-0{,}2156 \times 50) + 50 = 39{,}2$$

Hasil ini sama dengan nilai pada laporan (39,2) dan berada di bawah 50, yang berarti opini cenderung negatif. Nilai bootstrap persis tidak tercantum pada output; sebagai pendekatan analitis, simpangan baku skor s = $\sqrt{(0{,}527 - 0{,}2156^2)} \approx 0{,}693$, galat baku rata-rata $\approx 0{,}693 / \sqrt{167} \approx 0{,}0536$, atau sekitar 2,7 poin indeks. Maka selang 95% diperkirakan sekitar 34 sampai 44,5. Karena seluruh selang berada di bawah 50, kecenderungan negatif tidak sekadar kebetulan sampling, tetapi hanya berlaku untuk data yang dikumpulkan (lihat Bab 5).

3.4 Sentimen menurut Platform

Platform	Positif	Netral	Negatif
Twitter/X	30%	30%	40%
Instagram	16%	37%	47%
Facebook	11%	77%	11%

TikTok tidak muncul pada grafik karena tidak ada data asli yang lolos (data cadangan dummy sudah dikeluarkan dari analisis). Twitter/X memiliki sentimen positif tertinggi sekaligus negatif yang tinggi, menandakan opini yang terpolarisasi. Instagram paling negatif (47%). Facebook sangat dominan netral (77%).

3.5 Sentimen menurut Topik Program

Nilai berikut dibaca dari grafik batang bertumpuk 100% dan merupakan perkiraan visual, bukan angka tabel eksak.

Topik	Kesan dominan	Perkiraan komposisi (pos / net / neg)
Infrastruktur	Negatif terbesar	± 18 / 30 / 52
Politik & Janji	Negatif dan netral seimbang	0 / 50 / 50
Ekonomi & Harga	Negatif hampir setengah	± 15 / 43 / 42
Korupsi & Hukum	Netral dominan, negatif signifikan	± 5 / 57 / 38
Pendidikan (KIP/Beasiswa)	Netral dominan	± 16 / 47 / 37
Bansos & Perlinsos	Positif relatif tertinggi (di luar Ketenagakerjaan)	± 33 / 45 / 22
Kesehatan (BPJS/KIS)	Netral sangat dominan	0 / ± 83 / ± 17
Ketenagakerjaan	100% positif	100 / 0 / 0
Lainnya	Netral dominan	± 20 / 68 / 12

Kategori “Lainnya” dan “Ketenagakerjaan” perlu perhatian khusus: yang pertama menampung banyak berita yang tidak relevan dengan kinerja pemerintah, sedangkan yang kedua kemungkinan hanya berisi sangat sedikit teks sehingga persentase 100% tidak bermakna statistik.

3.6 Meme versus Non-Meme

Jenis konten	Positif	Netral	Negatif
Meme/Sindiran	0%	0%	100%
Non-Meme	16%	49%	35%

Konten meme/sindiran seluruhnya negatif. Pada konten non-meme, komposisinya mendekati distribusi keseluruhan.

4. Pembahasan

Kecenderungan negatif. ISB 39,2 menunjukkan bahwa percakapan yang terjaring lebih banyak bernada kritik daripada apresiasi. Namun hampir separuh data netral, sehingga arah indeks berasal dari selisih kecil antara 62 data negatif dan 26 positif, bukan dari mayoritas yang mengkritik. Interpretasi yang lebih aman: di antara pengguna yang beropini jelas, keluhan sekitar 2,4 kali lebih banyak daripada pujian.

Perbedaan antar platform. Pola ini sejalan dengan karakter platform. Twitter/X dan Instagram berisi komentar atau keterangan pribadi yang beropini, sehingga sentimen negatifnya tinggi. Facebook pada penelitian ini bersumber dari akun media berita yang mengunggah berita, sehingga netral mendominasi. Dengan demikian, rendahnya negatif di Facebook tidak berarti puas, melainkan karena teksnya berupa pemberitaan.

Efek sarkasme dan meme. Meme/sindiran 100% negatif konsisten dengan sifat sindiran, tetapi sebagian bersifat sirkular: pola deteksi meme (pov, katanya, klasik, padahal) bertumpang tindih dengan pola koreksi sarkasme yang memaksa label Positif menjadi Negatif. Selain itu meme yang awalnya Netral tetap Netral karena koreksi hanya berlaku pada Positif. Jumlah meme yang kecil (14 data) juga membuat angka 100% mudah berubah bila ada data tambahan.

Topik yang menonjol. Infrastruktur dan Politik & Janji terbaca paling negatif, sejalan dengan keluhan umum soal jalan rusak, banjir, dan janji kampanye. Bansos relatif lebih positif karena adanya apresiasi terhadap bantuan yang diterima, meski keluhan soal ketepatan sasaran dan keterlambatan pencairan tetap ada. Kesehatan didominasi netral, yang kemungkinan mencerminkan banyaknya berita informatif.

Kualitas data dan klasifikasi topik. Cuplikan 30 data pada laporan memperlihatkan sejumlah masalah yang mempengaruhi validitas:

- Banyak teks bukan opini publik tentang kinerja pemerintah, misalnya berita roket Jepang, orangutan, Kim Jong-un, dan bola, tetapi tetap ikut dihitung.
- Beberapa teks hanya berisi “Baca selengkapnya” dengan tautan sehingga tidak memiliki isi sentimen.
- Pelabelan topik berbasis substring menghasilkan salah label, misalnya berita bayi orangutan, perkara anak berhadapan dengan hukum, dan pengusaha katering dibegal dikelompokkan sebagai Infrastruktur; artikel es kering dikelompokkan sebagai Ketenagakerjaan; dan artikel jurusan ekonomi terbaik dinilai Positif sehingga dikaitkan dengan Ekonomi & Harga. Penyebabnya, kata

kunci pendek (misalnya “kis”, “kerja”, “jalan”) dapat cocok dengan bagian kata lain dan kategori dipilih berdasarkan urutan kamus.
- Label sentimen untuk berita bersifat negatif secara topik (misalnya pembegalan, kebakaran) tidak sama dengan sikap terhadap pemerintah; model hanya mendeteksi nada teks.

Dengan demikian, angka di atas lebih tepat disebut “sentimen nada teks pada percakapan bertema pemerintahan” daripada “kepuasan publik terhadap kinerja pemerintah”.

5. Keterbatasan

1. **Bias sumber.** Facebook hanya dari tiga akun media, TikTok tidak terwakili, dan pengambilan melalui kata kunci tidak mewakili seluruh populasi pengguna internet Indonesia.
2. **Relevansi.** Belum ada filter yang memastikan teks memang membahas kinerja pemerintah.
3. **Topik satu label.** Satu teks hanya mendapat satu topik padahal sering membahas beberapa isu; pencocokan substring menimbulkan salah label.
4. **Sarkasme berbasis aturan.** Daftar pola dapat melewatkan sindiran lain dan sebaliknya mengubah kalimat tulus yang kebetulan memuat kata seperti “katanya” atau “padahal”.
5. **Belum ada evaluasi akurasi.** Tidak ada data berlabel manusia sehingga akurasi, presisi, recall, dan F1 belum dapat dilaporkan.
6. **Ukuran sampel kecil per kelompok.** Persentase pada kategori kecil (Ketenagakerjaan, Politik & Janji, Meme) sangat tidak stabil.
7. **Konsistensi pelaporan.** Jumlah total pada PDF (177) berbeda dari grafik (167); sebaiknya dilaporkan satu angka dengan keterangan jelas.
8. **Tidak ada uji signifikansi antar kelompok.** Perbedaan antar platform dan topik belum diuji secara statistik (misalnya uji chi-kuadrat).

6. Kesimpulan dan Saran

Pada 167 data media sosial asli, sentimen terhadap isu pemerintahan terdistribusi 15,6% positif, 47,3% netral, dan 37,1% negatif dengan ISB 39,2 (perkiraan selang 95% sekitar 34–44,5), menunjukkan kecenderungan negatif. Instagram dan Twitter/X lebih negatif dibanding Facebook, sedangkan konten meme/sindiran seluruhnya negatif. Pendekatan ensemble yang dikombinasikan dengan koreksi sarkasme layak dipakai sebagai alat pemantauan awal, tetapi hasilnya belum dapat disimpulkan sebagai kepuasan publik sebenarnya.

Saran perbaikan:

- Tambahkan penyaringan relevansi (misalnya klasifikasi zero-shot atau daftar kata kunci wajib) sebelum analisis sentimen.
- Ambil komentar warga, bukan hanya unggahan akun media berita.
- Ganti pencocokan substring dengan pencocokan kata utuh (batas kata), dukung multi-label topik, atau gunakan klasifikasi topik berbasis model.
- Buat set data berlabel manual (minimal beberapa ratus teks) untuk mengukur akurasi dan F1, lalu sesuaikan ambang 0,55 dan aturan sarkasme.
- Laporkan selang kepercayaan per topik dan platform serta gunakan uji chi-kuadrat untuk perbandingan antar kelompok.
- Pertimbangkan model sarkasme terlatih atau fine-tuning pada data sindiran politik Indonesia.

Daftar Pustaka

1. Barbieri, F., Anke, L. E., & Camacho-Collados, J. (2022). XLM-T: Multilingual language models in Twitter for sentiment analysis and beyond. *Proceedings of LREC 2022*.
2. Conneau, A., et al. (2020). Unsupervised cross-lingual representation learning at scale. *Proceedings of ACL 2020*.
3. Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *The Annals of Statistics, 7*(1), 1–26.
4. Liu, Y., et al. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv:1907.11692*.
5. Wolf, T., et al. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of EMNLP 2020: System Demonstrations*.
6. Wongso, W. (2021). indonesian-roberta-base-sentiment-classifier [Model]. Hugging Face (w11wo).